

비트코인 상승/하락 시계열 분류 예측

RECSYS-08조 LEVEL1 프로젝트 랩업 리포트

프로젝트 개요

프로젝트 개요

프로젝트명 : 비트코인 상승/하락 시계열 분류 예측

소개 : 비트코인 가격의 1시간별 등락을 예측하는 AI 모델 개발

기간 : 2024.09.10~2024.09.26(2주)

예측 타겟 : 이전 시점 대비 다음 시점에서
증가의 등락 percentage
4가지 class(0, 1, 2, 3)

평가지표 acc, auroc, precision, recall, f1

클래스	설명
0	-0.5% 미만
1	-0.5% 이상 0% 미만
2	0% 이상 0.5% 미만
3	0.5% 이상

팀 구성 및 역할

팀원 수 : 6명

주요 역할 : 도메인 리서치, 데이터 전처리,
피처 엔지니어링, 모델 구현 및 학습

팀 구조 :

도메인 리서치(전원)	
EDA(전원)	
전처리 데이터 박광진 박재현 배현우	피처 엔지니어링 김영찬 박세연 조유솔
모델링(전원이 서로 다른 모델로 실험)	

*팀 내 역할분담 표

협업/개발 툴

코드 공유

깃허브

실험 관리

노션 Teamspace (마일스톤 정의 및 그라운드 룰 관리)

개발 환경

- IDE: VSCode, Google Colab
- 작업 환경: 로컬, Google Colab, 원격 GPU 서버(Linux V100 서버)
(원격 GPU 서버 사용 중 서버 다운으로 인한 데이터 손실로 불가피하게 Colab사용)

워크플로우

- 노션에 진행할 실험 정리 및 업무 분담
- Git branch convention 설계, main에 베이스라인 코드 마련
- branch 단위로 실험 진행 후 이슈에 정리
- 실험 결과 Git Issue를 통해 공유, 토의 후 메인 브랜치로 merge

기술 스택

- ML/DL 프레임워크 : PyTorch, scikit-learn
- 모델: LightGBM, XGBoost, Bagging 등
- 시각화: Seaborn, Matplotlib, Plotly
- 기타: NumPy, pandas, PyWavelets 등

데이터셋 소개


소개

Cryptoquant에서 제공한 비트코인 온체인 데이터

구성

크게 아래의 2가지 주요 항목으로 구성된다


	네트워크 데이터(Network Data)	시장 데이터(Market Data)
정의	→ 블록체인 자체에서 파악할 수 있는 데이터 → 블록체인의 활동 반영	→ 시장 정보와 관련된 데이터 → 시장에서 이루어지는 거래와 관련
역할	시장의 움직임 파악	가격 변동성 분석 및 예측
예시	해시레이트, 블록 리워드	코인베이스 프리미엄, 펀딩 레이트



칼럼 구조

- 총 107개의 csv 데이터 파일에 포함된 칼럼
- 각 csv 파일 별, {interval}_{category}_{endpoint}_{exchanges|symbol}의 구조로 구성
 - interval - 데이터 수집 간격, 시간 단위로만 구성(Hourly)
 - category - 대분류. Market Data와 Network Data로 분류
 - endpoint - 대분류에 따른 여러 소분류
 - exchanges|symbol - 거래소 명 or 암호화폐 종류

세부사항



<2023년의 종가, 거래량>

3월 → 거래량을 수반한 단기 가격급등
6, 10월 → 거래량은 수반하지 못한 급등
8월 → 거래량을 수반하지 못한 급락

Red: Volume(거래량)
Blue: Close(종가)



변동폭이 큰 클래스인 0, 3의 데이터 부족
→ 클래스 불균형 현상에 집중

ISSUE 1. 클래스 불균형 해소

프로젝트 수행 절차 및 방법

이슈	클래스 불균형 문제로 예측 클래스가 1, 2에 쏠리는 현상 발생.		
원인 분석	클래스 간 비율이 달라 다수 클래스에 대해 학습 할 기회가 더 많고, 다수 클래스로 예측을 하는 편이 목적 함수를 최적화 하는 방향에 유리함		
실험	업샘플링, 샘플 가중치 설정, 계층 샘플링, Focal Loss		
실험 내용	• 실험 A. 업샘플링: 여러 SMOTE 베리에이션, ADASYN을 적용. 특히 TSMOTE의 슬라이딩 윈도우를 사용해 하이퍼 파라미터를 변경하며 클래스 간 데이터 비율을 맞춤. • 실험 B. 샘플 가중치 설정: 소수 클래스에 가중치를 주어 모델이 소수 클래스에 대한 목적함수를 더 집중해서 최적화 할 수 있게 함. • 실험 C. 계층 샘플링 학습/검증 데이터 분리 시에 계층적 샘플링을 사용하여 학습과 검증 단계에서의 클래스 분포가 동일하게 유지되도록 함. • 실험 D. Focal Loss 목적함수로 Focal Loss를 사용해 모델이 어려운 예제에 집중하고 쉽게 맞추는 예제의 기여도를 낮춰 불균형에 영향을 덜 받도록 함.		
결과	적용 기법	구체적 방법	주요 결과
	업샘플링	SMOTE 기반, ADASYN, TSMOTE 등을 적용하여 소수를 다수 클래스의 비율에 가깝게 업샘플링	SVM SMOTE: val acc, auroc 등 전체적으로 좋은 결과 였으나 0, 3 target에 대한 recall은 작음 TSMOTE: recall은 가장 높았지만 precision이 낮아 val acc, auroc 저하
	샘플 가중치	소수 클래스에 높은 가중치 부여, 학습 시 집중	Recall 큰 폭 향상, Precision 준수, 전체 ACC와 AUROC 감소
	계층 샘플링	학습/검증 데이터의 클래스 분포 유지	학습/검증 단계에서 의미 있으나 인퍼런스에 적용 어려움
	Focal Loss	어려운 예제에 집중, 쉬운 예제 기여도 감소	Precision 향상, Recall 감소, 전체적으로 개선이 낮음

대체로 전체 ACC와 AUROC가 감소
대신 소수 클래스(0, 3번)의 예측 성능 향상
▶ 추가적으로 샘플 가중치 최적화, SVM SMOTE와 TSMOTE의 후속 실험 등이 필요
BUT 전체 성능에 집중하여 기법을 채용 X

ISSUE 2. 시계열 피처 엔지니어링

프로젝트 수행 절차 및 방법

이슈

feature engineering 단계에서, 기존의 feature만으로 모델을 학습시키는 과정 중 성능이 충분히 개선되지 않는 과소적합을 발견함.

원인 분석

기존의 feature만으로는 데이터의 복잡한 패턴을 트리 기반 분류기가 충분히 포착하지 못함.

초기 실험에서는 기존 feature + shift 만을 사용했으나 시계열 데이터를 잘 나타낼 수 있는 추가적인 feature가 필요함.

실험

문제 해결을 위해 지수 이동 평균(EMA)과 웨이블릿 변환(WT)을 추가한 새로운 feature들을 실험함. EMA는 주어진 feature들의 장기적인 추세를 반영하며, WT는 데이터의 비선형적인 변화 패턴을 포착할 수 있도록 돕는 방법으로 사용됨.

실험 내용

- (1) EMA: feature들의 가중 평균을 계산하여 장기적 추세를 반영.
- (2) Wavelet Transform: feature들의 변동 패턴을 다중 스케일에서 분석.
- (3) (1), (2)를 통해 각 feature(약 200개, 수치형 변수)가 제공하는 정보를 추가한 것을 바탕으로 예측 모델을 학습시킴.
- (4) 데이터 전처리 후 모델을 재학습하고 교차 검증을 통해 결과 확인. 간격과 임계값을 조정해가며
(1)~(3) 과정을 반복하는 여러 실험을 거친 뒤 Validation data에서 가장 성능이 좋은 값을 사용.

결과

- EMA와 WT를 추가한 후 모델의 예측 정확도가 기존 대비 상승.
- EMA는 특히 추세 추종 전략에서 강건하여 보였고, WT는 비정상적인 feature들의 변화에서 신호를 포착하는 데 도움을 줌.
- ACC: 약 2% 향상 (EMA와 WT를 사용한 조합에서 42%에 도달)

ISSUE 3. Open Interest 기반 피처 엔지니어링


프로젝트 수행 절차 및 방법

이슈	베이스라인 모델의 valid 데이터에 대한 성능을 평가하는 과정에서 과소적합됨을 확인. 특히, 에폭별 성능 line plot에서 에폭을 거듭함에도 train 데이터 대비 valid 데이터의 성능 향상이 저조함을 시각적으로 확인함
원인 분석	기존의 피처들의 타깃값에 대한 설명력이 부족하다고 판단, 모델의 설명력을 향상시키기 위하여 target변수와의 관련성이 높은 새로운 변수 생성이 불가피함
실험	상관계수와 도메인 지식을 활용한 피처 엔지니어링 실험과 SHAP value를 통한 피처의 영향력 분석
실험 내용	• (1) 상관계수 확인: target변수가 파생된 close변수와 모든 변수들 간의 pearson correlation coefficient 값을 비교, 가장 높은 값을 보유한 피처를 추출 • (2) 패턴 확인: 추출된 피처인 open-interest와 close피처의 시간에 따른 경향성을 시각화, 그래프 증감여부 및 증감폭에서 유사한 패턴을 확인. • (3) 가설 설정: test 데이터에 존재하지 않는 close변수에 내재된 정보를 open-interest 변수가 대체할 수 있을 것 • (4) 피처 엔지니어링: open-interest의 차분 및 변동성을 각각 새로운 피처로 추가
결과	EMA와 WT를 추가한 후 모델의 예측 정확도가 기존 대비 상승.
추가 이슈	월, 요일, 시간 등 날짜와 직접적으로 관련이 있는 데이터 이외에 장기적인 시계열 정보를 내포하는 변수가 부족. 결국 장기적인 패턴(비트코인 상승장/하락장)을 학습하지 못함.
원인 분석	차분과 변동성은 2개의 연속된 행의 값을 이용하여 계산되기에 1시간 이전의 데이터만 현재 데이터의 피처에 반영됨.
재실험	• 솔루션: Rolling Feature 추가 • 가설: 1시간 단위인 차분/변동성 feature와는 차별화되도록 보다 긴 시간 단위로 open-interest의 이동평균을 계산해 새로운 피처로 활용시 장기적인 예측력이 향상될 것 • 실험 과정: 롤링의 interval을 달리해가며 open-interest, open-interest차분값, open-interest변동성에 대한 이동평균 값을 추가한 뒤 베이스라인 모델 학습 및 평가
결과	인터벌을 6시간, 12시간, 24시간, 48간 간격으로 설정하여 이동평균을 추가한 결과, 2023년비트코인 시장의 장기적인 패턴(상승장)을 보다 잘 반영한 예측값을 도출함

결과 해석

Date	Model	Data	Accuracy	Accuracy (final)
2024.09.11 16:05	LGBM	All Features	0.3793	0.4090
2024.09.11 19:12	LGBM	상관계수 고려	0.3885	0.4126
2024.09.13 14:29	LGBM	All Features (Optuna)	0.3956	0.4082
2024.09.13 22:47	LGBM	결측치_이상치 처리	0.3821	0.3981
2024.09.16 15:36	LGBM	EMA 7	0.4020	0.4118
2024.09.16 16:10	LGBM	EMA WT	0.4070	0.4249
2024.09.19 15:42	LGBM	RF 기반 Feature Selection	0.2457	0.2587
2024.09.23 18:19	LGBM	SMOTE	0.4041	0.4191
2024.09.25 13:48	LGBM	세연+유술 피쳐	0.4155	0.3988
2024.09.25 14:41	LGBM	세연+유술 피쳐 + 결측치 앞뒤보간	0.4148	0.4118
2024.09.26 17:46	LGBM	All Features	0.3999	0.4010
2024.09.26 15:33	Ensemble - Bagging	All Features, Binary(증가/감소)	0.4162	0.4256
2024.09.25 21:35	Ensemble - Soft Voting	All Features	0.3928	0.4068
2024.09.25 23:29	Ensemble - Bagging	All Features	0.3942	0.4046
2024.09.12 21:59	LSTM	All Features	0.3707	0.3555
2024.09.16 18:18	LSTM	All Features + Bollinger Bands	0.3906	0.4205
2024.09.17 11:56	LSTM	All Features + Bollinger Bands	0.4027	0.4263
2024.09.26 17:58	LSTM	All Features	0.3807	0.3916
2024.09.16 00:26	DQN Reinforcement Learning	close 와 상관관계가 가장 높은 5 개의 데이터	0.2393	0.2290
2024.09.11 17:54	NeuralProphet	All Features	0.2955	0.3027
2024.09.12 14:38	XGBoost	All Features	0.3722	0.3801
2024.09.12 21:45	RandomForest	All Features	0.3871	0.3938
2024.09.24 14:09	Prophet	All Features	0.3501	0.3569

결과 해석



다양한 모델링 기법과 데이터 처리로 비트코인 가격 등락 예측 정확도 크게 향상시킴. 최종 모델이 베이스라인 대비 **오류율 6.87% 감소**시킴.
이는 금융 분야에서 의미 있는 개선으로 평가됨. 향후 실제 트레이딩 전략 수립에 유용한 인사이트 제공할 것으로 기대됨.

- **베이스라인 개선**: LGBM 베이스라인 모델(40.90% 정확도)에서 시작하여 최종 42.56% 정확도 달성함. 오류율 6.87% 감소.
- **특징 공학 효과**: EMA WT 적용 LGBM 모델이 42.49% 정확도 달성함. 베이스라인 대비 오류율 6.58% 감소.
- **앙상블 기법 성과**: Bagging 적용 결과 42.56% 최고 정확도 달성함. 단일 모델 대비 안정성과 성능 향상 입증.
- **모델 다양화**: LSTM 모델이 Bollinger Bands와 결합 시 42.63% 정확도 보임. 시계열 데이터 처리에 강점 나타냄.
- **데이터 처리 기법**: SMOTE 적용 LGBM 모델이 41.91% 정확도 달성함. 베이스라인 대비 오류율 4.16% 감소시킴.
- **지속적 성능 향상**: 초기 NeuralProphet 모델(30.27% 정확도)에서 최종 42.56%까지 향상함. 40.60% 성능 개선 달성함.

자체 평가 의견

프로젝트 초기 목표 달성정도

초기 목표: 높은 ACC의 비트코인 가격의 등락을 잘 예측하는 강건한 모델을 만들어 리더보드 1-2위 달성

성과: 데이터와 도메인 특성상 ACC를 대폭 향상하는 것이 불가능
베이스라인 대비 1.66%의 정확도 향상을 이루는 것에 그침
그러나 최종 리더보드 순위에서 3위를 하며 데이터 난이도 대비 상대적으로 높은 성능의 모델을 만든 것을 확인함

우수하게 수행된 요소

1. 전처리, 피처엔지니어링, 모델링에 걸쳐 다양한 실험을 진행함.
2. 깃헙을 통한 코드 공유, 회의를 통한 진지한 토론 등 모든 팀원들이 성실히 프로젝트에 임함.
3. 함수를 모듈화하여 클린 코드와 확장성 높은 코드를 구현함.
4. 전처리와 피처 엔지니어링 부분에서 역할 분담을 통해 업무 효율 증대
→ 각자 맡은 부분을 실험하고, 결과를 공유하여 유리한 방법을 적용

진행 과정 중 발생한 이슈와 향후 개선 방안

실험 신뢰성 부족	[Issue] WandB 툴을 사용한 실험 기록을 하지 않음 [Issue] 실험 결과가 돌릴때마다/팀원들마다 달라지는 경우 존재 [Action Item] WandB 툴 사용 + 템플릿을 통일해 자세히 실험 기록
협업 방식 논의	[Issue] 진도에 급급해 프로젝트 초반에 협업 방식에 대한 논의 진행 X [Issue] 브랜치/이슈/PR 등 깃헙 기능을 뒤늦게 사용, convention X [Action Item] 차기 프로젝트 초반에 다음 내용을 논의할 것 ○ 일정 관리 및 R&R(Role and Responsibility)을 정하기 ○ 깃/코드 convention, 이슈/PR/커밋 템플릿 정하기 ○ 깃헙 구조도, branch 구조도를 구상하기
버전 관리	[Issue] Baseline 코드를 하나로 통합하지 않음, 모델마다의 버전관리 X [Issue] 팀원 각자의 실험에 일관성X, 실험의 신뢰성 저하 [Action Item] ○ (통일) 모두가 같은 베이스라인을 기반으로 협업 ○ 코드 리뷰/데일리 스크럼을 통한 Ideation (각자 코드를 짜고 다시 합치는 과정)

개인 회고 [김영찬]

- 나는 내 학습목표 달성을 위해 무엇을 어떻게 했는가?

첫째, 프로젝트 시작과 동시에 평소 가장 관심 있던 분야인 강화학습 모델을 구현해보았다. 실력 향상을 위해 env 구현에 gym 라이브러리를 쓰지 않고, 최대한 직접 구현해보기 위해 구조를 고민하여 코드를 작성했다. 모델은 torch.nn을 상속받아 구현하였다.

둘째, 평소에 사용해보고 싶던 meta 사의 prophet 모델을 사용해보았다. Neuralprophet, prophet 두 가지 모델을 사용해보았다. 모델 사용 자체가 워낙 간단한 모델이다 보니, '이런 식으로 해야 하는구나'라는 인사이트를 어느 정도 얻어갔다.

마지막으로, 팀에 도움이 되고자 피쳐 엔지니어링 및 모델 앙상블에 집중하였다. 피쳐 엔지니어링에는 실패했지만, 모델을 앙상블하는 방법을 공부했다. 가장 나은 방법을 찾기 위해 앙상블 기법별로, 그리고 앙상블할 모델별로 실험을 진행했다. 실험 결과 최적의 모델을 팀원들에게 배포하였다.

- 나는 어떤 방식으로 모델을 개선했는가?

기존 단일 모델에서 앙상블 기법을 적용하였다. 여러 가지 기법 및 여러 가지 모델을 비교해보며 최적의 앙상블 기법을 찾아내는데 주력하였다.

- 내가 한 행동의 결과로 어떤 지점을 달성하고, 어떤 깨달음을 얻었는가?

결과를 산출물로 한정하면, 최종 제출물의 가장 좋은 결과에 내가 실험한 기법이 들어갔으므로, 팀적으로 5%정도 기여한 바가 있다. 내 산출물과 달성한 지점보다는, 실패에서 더 깨달음을 많이 얻은 프로젝트였다.

- 전과 비교하여 새롭게 시도한 변화는 무엇이고, 어떤 효과가 있었는가?

거의 대부분의 경험이 새로운 경험이었다.

- 마주한 한계는 무엇이며, 아쉬웠던 점은 무엇인가?

강화학습 : 기존의 방식이 아닌 내가 직접 만드는 방식이다 보니, 여러 곳에서 계속 에러가 났다. 입력 데이터가 계속 어긋나 모델이 돌아가지 않았고, 나중가서는 결국 라이브러리를 사용하여 환경을 구축하여 모델을 학습시켰다. 이 모든 과정에서 크게 스트레스를 받았다는 점이 아쉽다.

생각을 해보니, 개발자라는 직업은 결국 죽을때까지 창조하고, 창조의 과정에서는 에러가 필연적으로 발생한다. 그 에러 자체를 즐기는 마음가짐을 가져야 남들보다 한끗을 더 가진 개발자가 될 수 있을 것이라는 교훈을 얻었다.

또한, 결과물의 확률이 0.3을 넘기지 못했다. 찍는 것보다 안좋은 확률이 나왔다는 것인데, 강화학습 자체가 이 데이터와 잘 맞지 않다 생각하고 넘어갔지만, 데이터를 어떻게 잘 다뤘으면 괜찮지 않았을까 싶다.

피쳐 엔지니어링 : ‘내가 이걸 왜 해야하나’라는 근원적인 물음에 갇혀, 누구나 생각 가능한 이동평균, RSI 등 뻔한 데이터 이외의 데이터가 도저히 떠오르지 않았다. 저 물음은 '내가 이걸 왜 해야 하지?'와 같은 단순한 투정이 아니라, 크게 두 부분으로 나뉘어 있었다.

우선, 비트코인은 주식의 기업가치처럼 설명 가능한 미약한 연결고리도 없이 순수하게 사람의 욕망으로 움직이는 데이터가 아닌가? 찾을 수 없는걸 찾으려 하는 것이 아닌가 하는 물음이었다.

다른 한 가지 이유는 갈피를 잡지 못한 채 모호하게 머릿속을 떠돌다가, 9월 24일에 들은 특강에서 비로소 구체화되었다. 그 원인은 바로 ‘어떤 모델을 쓸 것인가’였다. 내가 이걸 진행하지 못한 이유는 결국 내 팀 협업 과정에서 발생한 문제였는데, 나는 모델을 독자적으로 짜고, 독자적으로 진행하며, 팀원과 경쟁하듯 프로젝트를 진행하였다. 그러니 나는 모델을 3번 바꾸어가며 프로젝트를 독자적으로 진행하였고, 갑자기 팀 전체가 사용할 데이터를 만들자니, 어느 모델에 맞추어 만들어야 할지 몰랐던 것이다. 협업 과정에서 중심이 되는 하나의 기준의 필요성을 느꼈다.

- 한계/교훈을 바탕으로 다음 프로젝트에서 시도해볼 것은 무엇인가?

역설적이게도 다음 프로젝트에서 시도해볼 것은 ‘팀 프로젝트’이다. 내 개인 공부를 목적으로 한 프로젝트는 뒷맛이 좋지 않다. 결국 나 혼자 진행하였기 때문에, 내 수준을 벗어난 인사이트를 얻기 힘들다. 부스트캠프의 강점은 커리큘럼과 강사진도 있지만, 높은 수준의 동료라는 사실을 깨달았으니, 이를 바탕으로 팀 협업에 집중해볼 것이다.

더해서, 버그 자체를 즐기는 마음가짐을 시도해볼 것이다. 스트레스 받는 상황에서 즐겁다, 신난다를 반복하면 즐거워지고 신난다. 난 문제해결을 신나게 즐길 것이다.

개인 회고 [박광진]

나의 학습목표 달성을 위해 무엇을 어떻게 했는가?

→ 처음 돌입하는 프로젝트인 만큼, 개발 및 실험 환경 구축에 익숙해지고 데이터를 보는 눈을 길러야겠다는 목표 달성을 다짐하였다. 이를 위해, Git, VSCode, Linux 코드 등 여러 프로그램 및 명령어에 익숙해지는데에 최우선을 두었다. 그리고 여러가지 환경을 구축해보며 친숙해지기 위한 시도를 끊임없이 반복하였다.

나는 어떤 방식으로 모델을 개선했는가?

→ Raw data의 해상도를 높이기 위해, 0이 많은 데이터를 제거하려고 시도하였다. 전체 Raw Data를 시각화 해본 결과, 값의 다수가 0인 데이터를 다수 발견하여서 이러한 시도를 하게 되었다. 0이 많은 데이터는 결측치처럼 성능에 영향이 미칠 것이라 예상하였다. 이에, 0의 값을 일정 비율 이상 포함된 데이터 파일들을 골라내는 함수를 만들어 적용하며 모델 개선을 위해 시도하였다.

내가 한 행동의 결과로 어떤 지점을 달성하고, 어떤 깨달음을 얻었는가?

→ 0의 값이 포함된 비율을 30, 50, 70프로 이상 포함된 경우로 나누어 모델의 성능을 테스트해 보았다. 그 결과가, 예상과는 다르게 큰 차이가 발견되지 않았다. 이를 실행해보고 난 후, 0의 값도 결측치가 아닌 하나의 데이터로서 작용하기'에 크게 성능의 변화가 없다는 생각을 하게 되었다. 처음에는 0의 값이 다수 포함된 데이터를 시각화해보고 굉장히 분포가 불균형한 데이터라고 인식하여 이러한 시도를 하게 되었는데, 제거는 그 답이 될 수 없다는 것을 깨닫게 되었다.

전과 비교하여 새롭게 시도한 변화는 무엇이고, 어떤 효과가 있었는가?

→ AI 모델을 처음 짜보는 것이어서, 처음부터 끝까지 하나의 모델을 만들고 적용하는 과정이 전부 새로웠다. 전처리, feature engineering, 모델 등 그간 Level 1.에서 배운 내용들을 이것저것 적용해보는 과정이 새로웠고 동시에 7주간 배운 내용을 한번에 실습으로 정리할 수 있는 기회가 되었다. 처음 부스트캠프를 시작할 때는, 말로만 듣던 이 모델을 구현하는 과정이 올라 했는데 그 과정이 7주 안에 이루어 질 수 있어서 성취감을 얻을 수 있었다.

마주한 한계는 무엇이고, 아쉬웠던 점은 무엇인가?

→ 아무래도 처음 배운 내용들을 정리하며 하다 보니, 여러가지 실험을 해볼 수 있는 물리적인 시간이 부족했던 점이 아쉬웠다. 또한 개발 환경을 구축하는 데 꽤 많은 시간을 소비하였고, 개발 환경에 익숙해 지는 데에도 꽤 오래 걸렸던 것 같아서 아쉬웠다. 또한 개인적으로 친숙하지 않았던 도메인이었어서, 좀 더 도메인에 대해 공부하고 프로젝트에 임하지 못한 아쉬움이 남았다.

한계/교훈을 바탕으로 다음 프로젝트에서 시도해볼 것은 무엇인가?

→ 이번 프로젝트가 앞으로 나아가기 위한 기폭제를 준비하는 프로젝트라 생각하고 다음 프로젝트는 이번 프로젝트에서 얻은 여러 경험 및 익숙함을 바탕으로 더 많은 실험을 시도해 볼 수 있도록 하고 싶다. 그리고 다음 프로젝트에는 반드시 데이터에 대한 분석을 자세히 한 후 돌입을 해야겠다고 마음 먹었다.

개인 회고 [박세연]

대회가 시작과 함께 데이터를 확인하고 데이터를 이해하기 위해 도메인 지식을 공부한 뒤, EDA를 시작했다. 주어진 데이터들 중 2022년 까지 밖에 수집되지 않은 파일을 발견하여 데이터를 불러와 합쳤을 때, NULL 값이 발생하는 이유를 파악했다. 그래서 모든 데이터를 사용하는 것이 좋은 것이 아니라 어떤 데이터를 사용할 지 파악하는 것이 중요할 것 같았다. 거래소나 암호 화폐 종류를 구분하도록 되어 있는 파일들은, 각각의 독립변수를 파악하고 분석하는 데에만 사용을 하는 것도 좋겠다는 생각이 들어 그 부분의 데이터를 제외하는 방법도 생각했다. 레이블의 분포를 보고 데이터 불균형이 심하다는 것을 파악했고, 많은 논문에서 훈련 데이터의 타겟 분포를 동일하게 학습 시키는 것을 중요하게 여긴다는 사실도 떠올랐다. 이로 인해 성능이 안 좋은 것일 수도 있으므로 minor한 타겟의 데이터 증강을 통한 실험을 했지만 정확도가 오르지 못하는 것으로 보아, 다른 이유들도 있는 것 같았다. 또한 주어진 데이터의 모든 독립변수들 간의 상관계수를 히트맵으로 출력하여 상관관계를 파악했다. 긴밀하게 연관된 컬럼들도 있었지만, 그렇지 않아보이는 컬럼도 있었다. 이 중 추가적인 EDA를 실행했다. 시간에 따른 종가(close)와 독립변수들의 변동을 비교해보았다. 그 중 가장 연관성 있어 보였던 것은 Open_interest와 UTXO였다. Close 데이터는 테스트 데이터셋에서 제공되지 않기 때문에 앞에서 언급한 비슷한 변동을 가지는 변수를 이용할 수 있지 않을까 생각했다. 이렇게 데이터에 대한 분석을 한 뒤 feature engineering을 했다. 비트코인과 주식에서 잘 사용되는 지표를 찾아보려고 생각했다. 그래서 볼린저 밴드(시장의 변동성), 지수 이동 평균(장기적 추세 반영), Wavelet transform(변동 패턴 포착) 이렇게 세 가지의 기법을 적용하여 새로운 컬럼을 만든 뒤 실험을 했다. 지수 이동 평균과 Wavelet transform에서 성능 향상을 보이는 것 같아 이 기법들을 사용해보고자 했다. 그리고 약간의 결측치가 존재하는 것을 확인했는데, 데이터 분석, feature engineering, 모델링을 할 때 영향을 미치기에 여러 보간 법을 실험해보고 선형 보간법을 사용하게 되었다. 모델링 시에 실험해 본 모델은 Decision Tree 기반의 Random Forest, XGBoost, LGBM 그리고 순환 신경망 모델인 RNN 기반의 LSTM이었다. 이때 LSTM은 Shift feature를 사용하는 것이 도움이 될지 궁금하여 실험을 한 결과 Shift feature를 제외한 경우의 실험 결과가 더 좋은 것처럼 보였다. 이후 앞에서 언급한 모델들로 Ensemble 기법 중 하나인 Voting을 시도했지만, 시간이 여유롭지 않아 LSTM을 포함한 앙상블 모델의 결과를 보지 못했다. 각 모델에 대한 하이퍼 파라미터 튜닝은 optuna를 이용했다. 큰 성능 향상을 기대하기보다 학습 데이터를 가장 잘 대표하는 최적의 하이퍼 파라미터를 적용할 수 있다는 점이 좋은 것 같다. 시계열 데이터를 많이 다루어 보지 않아서 feature engineering을 하는 데 어렵게 느껴졌는데, 이번에 다양한 기법을 찾아보고 적용해보아서 다음에 더 수월하게 진행할 수 있을 것 같다. 또한 비트코인에 대한 도메인 지식이 없어서 EDA를 하는 것이 조금 힘들었다. 그리고 Raw Data를 다뤄볼 수 있는 기회가 많이 없는데, 이번에 하나의 경험을 더 한 것 같아 앞으로 이렇게 경험치를 쌓아 나가서 실무에서 잘 사용할 수 있으면 좋겠다.

개인 회고 [박재현]

이번 프로젝트를 통해 AI 개발의 전반적인 단계를 처음부터 끝까지 경험하며, 데이터 수집, 전처리, 모델 개발, 평가, 그리고 결과 분석에 이르는 모든 과정을 체계적으로 학습할 수 있었다. 프로젝트를 진행하면서 주어진 데이터를 분석하고, 시각화를 통해 패턴을 탐색하며, 도메인 지식을 학습하는 과정에서 데이터와 관련된 도메인 이해가 모델 성능에 매우 중요한 영향을 미친다는 점을 깨달았다. 데이터를 어떻게 다루느냐에 따라 결과가 크게 달라질 수 있음을 인식했고, 데이터의 구조와 특성을 정확히 파악하고 이를 코드로 반영하는 과정이 중요하다고 판단했다.

먼저, 데이터의 시각화를 통해 예측 성능 향상에 중요한 변수가 무엇인지를 파악하고자 했다. 상관관계 분석과 유전 알고리즘을 활용하여 변수를 선택하고자 했으나, 전체 데이터셋을 사용한 경우와 비교했을 때 유의미한 부분집합을 도출하지는 못했다. 이는 도메인 지식의 부족이나 데이터 분석의 깊이가 부족했기 때문에 성과를 내지 못한 것 같아 아쉬웠다. 다음 프로젝트에서는 데이터를 더욱 심도 있게 분석하는데 중점을 두어, 그 분석에 기반한 설계로 코드를 작성해야겠다. 기존 데이터를 단순히 활용하는 것만으로는 부족하다는 판단 하에 피쳐 엔지니어링을 시도했다. 특히, close 데이터를 기반으로 이동평균을 만들어냈고, 볼린저 밴드와 같은 기술적 지표를 생성했고, .shift, 차분, 비율 등을 활용해 실험을 진행했다. 다만, close 데이터는 2024년 데이터가 없어 끝까지 사용하지 않았고, shift는 경우의 수가 너무 많아 baseline에서는 우선 배제하였다. 나머지는 유의미한 성능 향상을 보여 그대로 활용했다. 또, Quantile Transform이 성능을 소폭 개선시켰고, 스케일링 기법은 성능 개선 효과가 미비하여 최종적으로 배제하였다.

결측치 처리에서는 평균값과 중앙값을 사용하는 전통적인 방법 외에도 선형 보간법과 다항 보간법을 적용해보았고 선형 보간법을 채택했다. 다만, 결측치를 처리하는 방식이 결과에 큰 영향을 미친다는 생각이 들어, 다음 프로젝트에서는 결측치 처리 방법에 대해 더 깊이 탐구하고, 다양한 방법론을 시도해볼 계획이다.

모델링에선 CatBoost, XGBoost, LGBM, LSTM 등의 모델들을 적용해 보았고, LGBM이 가장 우수한 성능을 보였다. 이를 바탕으로, LGBM과 XGBoost를 결합한 스택킹 앙상블을 실험해봤는데 약간의 성능 향상은 있었다. 하지만 다른 앙상블 방법과 다양한 모델 조합을 충분히 실험하지 못한 점은 시간 부족으로 인한 아쉬움으로 남았다.

이번 프로젝트에서는 개인적으로 모든 과정을 직접 수행하고, 코드를 모듈화하여 효율성을 높이고 최종적으로 좋은 성능을 내는 것을 목표로 삼았다. 하지만 시간 관리 부족으로 인해 작업의 완성도를 충분히 높이지 못해 팀원들과 공유하지 못한 점이 아쉬웠다. 또한, 다양한 방법론을 모두 적용해보지 못한 점도 아쉬움으로 남는다. 다음 프로젝트에서는 시간 관리, 가정 수립, 결과 정리를 더 효율적으로 수행해 가능한 모든 방법을 시도하고 성능을 극대화할 수 있도록 할 것이다.

개인 회고 [배현우]

프로젝트 전반에 대한 개인적인 평가

과정을 보자면 도메인 지식도 알아와 적용시켜 보고, 다양한 실험 및 모델도 사용해본 모두가 열정적이었던 프로젝트였다. 야생 학습의 재미를 느껴볼 수 있었고 어렵고 힘들더라도 전혀 하기 싫지 않았다.

결과를 보자면 많은 시도와 노력에도 결과를 향상시키기 쉽지 않았다. 피처 엔지니어링을 제외하고는 도움이 될 것이라고 예상했던 시도들이 통하지 않아 막막했던 프로젝트였다.

내가 클래스 불균형 실험 정리하면서 얻은 인사이트

클래스 1, 2 번만 더 맞추려 하지 않고 0, 3에 이상치 탐지와 같은 목적으로 집중해본다면

val acc, auroc는 전체적인 그림만 알려 줄 뿐, 세부적인 그림은 알려주지 못한다라는 점

precision과 recall 값을 둘 다 살피며 어떤 실험을 진행 했을 때에 모델이 불균형 클래스에 대해서 어떻게 성능이 개선되는가를 확인 하는 법을 배웠다

내가 더 해보고 싶었던 부분

이것저것 시도해봐야 할 것이 많다는 압박에 개별 실험에 소홀해졌었다. 오픈 인터레스트 활용하기, price 예측으로 접근해보기 등 떠올렸지만 깊게 파고들지 않아 다른 팀의 발표를 보며 아! 저 부분 더 해볼걸 이라고 아쉬움이 깊게 남았다.

시계열 데이터답게 행 단위로 순차적으로 넣어서 학습시켜서 auto regressive하게 인퍼런스 하는 방법도 해보고 싶었다.

개인 회고 [조유솔]

- 문제: 전처리 / Feature Engineering
이 중에서 나는 F.E 담당
무슨 Feature를 새로 만들면 좋을지?
생각하며 EDA 진행

- 한일: 사실 안함!!
그나마 현우형이 open-interest 얘기 해주어서
그런 time에 따른 line plot이 전부...

- 성과: Feature Engineering 때
사용할 feature를 선별할 수 있었음.

- 아쉬운 점: 안했다..ㅠㅠ
항상 EDA가 고민인데.. 나만의 체계가 필요하더라.
RJ 시작하면 이것부터 항상 하게 될텐데.

* 앞으로는 how?
① target과의 시각화 -> subplot 써서 한눈에 볼 수 있게
② 시계열이라면, time에 따른 시각화 -> " (일괄적으로)
③ 두 변수의 연산(차이/비율 등) 시각화. (target과 함께)

①, ② 번은 Feature Selection 측면에서,
③ 번은 Feature Engineering 측면에서 유용할 듯.

EDA

1. 한일:
• 칼럼별 의미를 리서치하여 이해하려고 함.
동원들과 역할을 분담해 리서치하고, 정리하자고 제안함.
• 문제: EDA과정에서 방향, 방향을 잡지 못함.
당연히 각 칼럼의 의미를 모르니, 개념을 세우지 못하고, 결과의 의미가
univariate, bivariate 그래프 그려보기 (w/ target label)에 그침.
• Notion Teamspace에 RJ 페이지 열고 리서치 내용 정리.

2. 성과:
• 칼럼의 의미 조금이나마... 이해.
뭔가 정리하고 뭐가 더 중요하지 정도.

3. 아쉬운 점:
• EDA를 이걸 사용해서 진행하지 못함.
EDA의 리서치 -> 가설 -> EDA + Feature Selection
+ Feature Engineering

으로 이어져야 하는데 그러지 못함.
• why? 너무 많은 칼럼을 다 이해하려고 해서.
정리를 따져 중요했던 것만 선별해 가설(EDA를 진행해보자).
정리 따지는 법? -> 일단 target과의 시각화 결과 리서치.
시계열이면 time에 따른 lineplot도 결과 리서치.
그 다음엔... 다음 중요한 단계를 하나씩 정리 / 비율 / ...
등의 연산을 시각화!

도메인

* 앞으로 how?
EDA
→ EDA 전, 애부터!

칼럼의 의미 리서치
- 역할 분담
- 팀 페이스북
- 팀

→ 칼럼의 의미 이해
칼럼간의 상관
관계
(모두 이해하기보다
중요한 것부터)

→ 가설 세우기
↓
EDA
① target과의 분포
② time에 따른 lineplot
③ 가설의 시각화
→ 두 변수의 차이/비율...
등의 연산

← Feature Selection
← Feature Engineering

- 문제: Feature 너무 많음.
Sparse Feature도 많았다.

- 한일: RF, VarForm, 단일변수, 상관계수 ...
차원 축소(PCA, Kernel PCA, T-SNE)

- 성과: 모든 피처를 쓰지 않고
ACC와 AUROC
ACC와 AUROC (of LGBM)을 비교(가설)해가며
가장 성능이 높은 feature를 찾아내기 위한 실험을 진행.
가장 좋은 성능을 가진 feature를 찾아냄.
안타깝게도...? 사용하지 못함. 성능 ↓
(같은 코드? 있었는데 머신설로 기억)

- 아쉬운 점: 왜인지 실험 결과가 들릴 때마다 달라짐. (비전과 차이 있음)
원래는 RF로 하려고 했는데.. 이걸 그냥 다 쓰게 됨.
차원 축소는 그냥 GPT가 알려준 대로 했는데..
사실 아직 이해하지 못했다.

피처 선택

* 앞으로 how?
WandB 사용 방법 익히기
→ 여기에 실험 결과 기록 } 좀 정리할 듯.
차원 축소, 이번엔 이해 X지만 다음번엔
이해 후 제대로 적용해보기 (이제 애만 해볼 make)
VScode로 작업하기. for 버전 관리!
코드 정리는 github (나만의 private 리포 만들기)
→ 여기에 비록 경험은 아님, 나만 쓰는 내 저장공간이지만
git push, merge, branch ...
등을 진행하자.

- 문제점: Feature Selection에서 성과가 X.
→ 데이터가 좀 거지같다. 좋은 피처를 꼭 만들어야
하니까, 이게 핵심이 될 거라고 생각.

- 한일: Rolling Feature
Domain Feature
Date Feature.
Open-Interest Feature.
모듈화(함수로)

- 성과: 성능 향상

- 아쉬운 점: Confusion Matrix도 해석하면서
성능을 check 했어야 했는데 ACC, AUROC만 봄.
심지어 AUROC는 의미도 잘 모름.
변수명을 복잡하게 설정했다 뒤늦게 간파해서 변경했음
모듈화해서 기억한다면? 리팩토링
처음부터
계속.. 나만 쓴.. 사용성이 별로가..?
동원들에게 공유되지 X..
나의 피처가 좋다는 걸 실증할 수 있어야 함.
그러기에는 ACC, AUC, AUROC로는 부족하고
나의 '해석' (왜 좋았는지에 대한)이 들어야 함.
→ 이걸 할 줄 아려면 내가 잘 이해하는 것이 우선!

피처 엔지니어링

변수명
리팩토링
리팩토링하기

→ function으로
모듈화된 형태로
만들 것

→ 변수의 영향력 해석할
때, ACC와 AUROC 말고
다른 지표 (Confusion Matrix)
도 볼 것.
↓
지표가 올랐다고 해서 내가
왜 편지 '해석'을 할 것.

→ 동원들에게
전달, 실득

↓
또 배포
(사용성 좋게...)